

ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA TOÁN - ỨNG DỤNG



BÀI TẬP NHÓM
HỌC PHẦN: HỌC SÂU (858048)

Giảng viên đảm nhiệm: TS. Đỗ Như Tài

Họ và tên sinh viên: Trần Quốc Hoàng

Mã số sinh viên: 3123580015

Lớp: DDU1231

Thành phố Hồ Chí Minh, ngày 27 tháng 09 năm 2026

1. Business Understanding (Thấu hiểu kinh doanh)

1.1. Bối cảnh và động lực

Thị trường bất động sản là một trong những lĩnh vực có tổng giá trị giao dịch lớn nhất trong nền kinh tế. Tuy nhiên, việc định giá một căn nhà gặp nhiều khó khăn do chịu ảnh hưởng đồng thời bởi hàng loạt yếu tố phức tạp: diện tích, vị trí địa lý, chất lượng xây dựng, năm hoàn thiện và các tiện ích đi kèm. Phương pháp định giá thủ công truyền thống thường tốn nhiều thời gian và dễ mang tính cảm quan cá nhân.

1.2. Mục tiêu dự án

Mục tiêu kỹ thuật: Xây dựng mô hình Mạng nơ-ron đa tầng (Multi-Layer Perceptron - MLP) trên nền tảng PyTorch có khả năng dự đoán chính xác giá bán của từng căn nhà dựa trên các thuộc tính mô tả.

Mục tiêu ứng dụng: Cung cấp công cụ định giá tự động, hỗ trợ nhà đầu tư, người mua và các đơn vị môi giới bất động sản đưa ra quyết định nhanh chóng và có cơ sở khoa học.

1.3. Tiêu chuẩn đánh giá

Dự án sử dụng độ đo RMSLE (Root Mean Squared Logarithmic Error) làm chỉ số đánh giá chính:

$$\text{RMSLE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(y_i + 1) - \log(\hat{y}_i + 1))^2}$$

Lý do chọn RMSLE: Độ đo này tính toán sai số tương đối giữa tỷ lệ giá trị dự đoán $\hat{y}_i$ và giá trị thực tế y_i , giúp giảm bớt tác động tiêu cực từ các bất động sản có giá trị cực cao và phạt nặng hơn đối với trường hợp dự đoán thấp hơn thực tế.

Mục tiêu và kết quả thực tế: Mô hình hướng tới $\text{RMSLE} < 0.1500$. Kết quả thực tế nộp lên hệ thống Kaggle lại đạt được 0.14852.

2. Thấu hiểu về dữ liệu

2.1. Tổng quan tập dữ liệu

- **Tập huấn luyện (*train.csv*):** Gồm 1,460 mẫu dữ liệu với 79 đặc trưng đầu vào và 1 biến mục tiêu (SalePrice).
- **Tập kiểm tra (*test.csv*):** Gồm 1,459 mẫu dữ liệu với 79 đặc trưng đầu vào (cần dự đoán SalePrice).

Phân loại đặc trưng:


- **Đặc trưng số:** 36 biến (ví dụ: LotArea, GrLivArea, TotalBsmtSF, GarageCars,...).
- **Đặc trưng định tính:** 43 biến (ví dụ: Neighborhood, HouseStyle, SaleCondition,...).

2.2. Phân tích khám phá dữ liệu

Phân bố biến mục tiêu (SalePrice): Biến mục tiêu bị lệch phải rõ rệt (Right-skewed), tập trung chủ yếu trong khoảng từ 100,000 USD đến 250,000 USD. Một số ít căn nhà có giá trị vượt trội lên tới 750,000 USD.

Giá trị khuyết thiếu:

- Nhiều biến định tính có tỷ lệ thiếu rất cao như PoolQC (> 99%), MiscFeature (> 96%), Alley (> 93%), Fence (> 80%).
- Nguyên nhân là do các căn nhà không sở hữu các tiện ích này (không có bể bơi, không có lối đi riêng,...).



Hình 2.1: Tổng quan dữ liệu giá nhà

Đánh giá:

- **Trước biến đổi Log:** Giá bán thực tế bị lệch phải nặng, gây khó khăn cho việc tối ưu hàm MSELoss trong mạng nơ-ron.
- **Sau biến đổi Log:** Phân bố chuyển sang dạng chuẩn, giúp Gradient Descent hội tụ nhanh và ổn định hơn.
- **Dữ liệu thiếu:** Các thuộc tính như PoolQC, MiscFeature, Alley, Fence thiếu > 80%, minh chứng cho việc cần áp dụng One-Hot Encoding kết hợp SimpleImputer ở bước Data Preparation.

3. Tiền xử lý dữ liệu

Để đảm bảo mô hình MLP đạt hiệu năng tối ưu và tránh hiện tượng rò rỉ dữ liệu, quy trình tiền xử lý được thực hiện chặt chẽ theo các bước:

3.1. Xử lý ngoại lệ

Loại bỏ các điểm dữ liệu bất thường cực đoan dựa trên đồ thị phân tán giữa GrLivArea (diện tích sống trên mặt đất) và SalePrice. Cụ thể:

- Xóa bỏ các quan sát có *GrLivArea* > 4000 *sqft* nhưng *SalePrice* < 200,000 *USD*.
- Kích thước tập train sau khi lọc: Giảm từ 1,460 xuống còn 1,458 mẫu.

3.2. Chuẩn hóa biến mục tiêu

Thực hiện phép biến đổi $\log(1 + x)$ đối với biến SalePrice:

$$y_{\log} = \log(1 + \text{SalePrice})$$

Phép biến đổi này giúp đưa phân bố lệch phải của giá nhà về dạng chuẩn (Gaussian Distribution), tạo điều kiện thuận lợi cho hàm mất mát MSE trong quá trình huấn luyện mạng nơ-ron.

3.3. Mã hóa biến phân loại và điền khuyết

- **Xử lý biến định tính:** Áp dụng phương pháp One-Hot Encoding cho toàn bộ 43 biến định tính, mở rộng không gian đặc trưng từ 79 lên 266 đặc trưng.

- **Điền giá trị thiếu:** Sử dụng `SimpleImputer(strategy='median')` để điền các giá trị thiếu ở các biến định lượng.
- **Phòng tránh Data Leakage:** Việc fit Imputer chỉ được thực hiện duy nhất trên tập huấn luyện (`train_split`), sau đó mới dùng để transform lên tập validation và test.

3.4. Chuẩn hóa đặc trưng

Đặc trưng đầu vào (X): Áp dụng `StandardScaler` để đưa toàn bộ 266 đặc trưng về phân bố chuẩn có trung bình $\mu = 0$ và độ lệch chuẩn $\sigma = 1$:

$$X_{scaled} = \frac{X - \mu}{\sigma}$$

Biến mục tiêu (y): Tiếp tục thực hiện Z-score normalization trên biến y_{log} trước khi đưa vào Mạng Nơ-ron PyTorch để tối ưu quá trình tính toán Gradient Descent.

4. Xây dựng mô hình

4.1. Kiến trúc mạng nơ-ron PyTorch MLP

Mô hình PyTorch MLP được thiết kế với cấu trúc mạng đa tầng bao gồm các kỹ thuật kiểm soát quá khớp:

- **Input Layer:** 266 nút (tương ứng 266 đặc trưng sau tiền xử lý).
- **Hidden Layer 1:** 128 nút $\rightarrow$ Activation: ReLU $\rightarrow$ Dropout(0.2).
- **Hidden Layer 2:** 64 nút $\rightarrow$ Activation: ReLU $\rightarrow$ Dropout(0.2).
- **Output Layer:** 1 nút (Dự đoán giá trị y ở dạng Z-score).

4.2. Thiết lập thông số huấn luyện

- **Hàm mất mát:** Mean Squared Error Loss (`nn.MSELoss()`).
- **Thuật toán tối ưu:** Adam Optimizer (`torch.optim.Adam`) với tốc độ học `learning_rate = 0.001`.
- **Kích thước Batch:** 32 mẫu/lô.
- **Số lượng Epoch:** 150 epochs.

- **Cơ chế Early Stopping / Model Checkpoint:** Theo dõi giá trị RMSLE trên tập kiểm định sau mỗi epoch và tự động lưu trạng thái tốt nhất (best_model_state).

5. Đánh giá mô hình

5.1. Kết quả chỉ số định lượng


Mô hình đạt được kết quả huấn luyện tối ưu với các thông số chi tiết:

- **Epoch đạt RMSLE tốt nhất:** Epoch thứ 12.
- **RMSLE trên tập kiểm định:** 0.1428.
- **Kết quả đánh giá trên Kaggle:** 0.14852.
- **Đánh giá mức độ lệch:** Độ chênh lệch giữa Validation RMSLE (0.1428) và Kaggle (0.14852) chỉ là 0.0057 (< 0.01). Điều này chứng minh quy trình chia tập dữ liệu và chuẩn hóa không bị rò rỉ dữ liệu, mô hình có khả năng tổng quát hóa rất tốt trên tập dữ liệu hoàn toàn mới.

5.2. So sánh đặc tính mô hình

Tiêu chí so sánh	Mô hình MLP gốc (Chưa tối ưu)	Mô hình PyTorch MLP (Đã tối ưu)
Xử lý Outlier	Giữ nguyên dữ liệu gốc	Lọc bỏ điểm ngoại lệ (GrLivArea > 4000)
Phân bố dữ liệu đầu vào	Chưa qua biến đổi Log	Chuyển đổi log (1 + SalePrice) & Z-score
Kiểm soát Overfitting	Không có Dropout	Tích hợp Dropout (0.2) & Checkpoint Epoch 12
Validation RMSLE	> 0.2200	0.1428
Điểm submit trên Kaggle	> 0.2300	0.14852
Tính ổn định của Residuals	Sai số lệch lớn ở giá cao	Sai số phân bố chuẩn dạng Gaussian quanh 0.0

5.3. Phân tích đồ thị kết quả



Đồ thị tương quan: Các điểm dữ liệu nằm phân bố rất sát đường phân giác $y = x$. Mô hình dự đoán chuẩn xác trên đa số phân khúc giá, chỉ có xu hướng dự đoán thấp hơn một chút ở nhóm nhà cực kỳ cao cấp ($> 450,000$ USD) do mẫu dữ liệu nhóm này ít.

Đồ thị sai số: Độ lệch sai số ($y_{true} - y_{pred}$) tuân theo phân bố chuẩn có đỉnh tại gốc 0.0 và biên độ sai số hẹp $[-0.2, 0.2]$, chứng minh mô hình không bị chệch lệch hệ thống.

6. Triển khai và dự đoán

6.1. Quy trình biến đổi ngược

Sau khi thu được đầu ra dự đoán $\hat{y}_{scaled}$ từ mô hình PyTorch trên tập kiểm tra (*test.csv*), dữ liệu được khôi phục về thang giá USD thực tế qua các bước:

Re-scale Z-score về Log Scale: $\hat{y}_{log} = (\hat{y}_{scaled} \times \sigma_y) + \mu_y$

Chuyển đổi hàm mũ ngược: $SalePrice_{final} = \exp(\hat{y}_{log}) - 1$ (sử dụng hàm *np.expml*).

6.2. Xuất kết quả dự đoán

Dữ liệu dự đoán cho 1,459 căn nhà trong tập test được đóng gói vào file *submission.csv* gồm 2 cột: Id và SalePrice.

Kết quả kiểm tra tính hợp lệ: Không chứa giá trị NaN, giá trị khuyết hoặc giá trị âm, sẵn sàng nộp lên hệ thống đánh giá Kaggle.