

Chương 2

Hồi quy Logistic

2.1 Giới thiệu về hồi quy logistic

Hồi quy logistic (logistic regression) (Tolles and Meurer, 2016) là mô hình được đặt tên dựa trên hàm số đóng vai trò cốt lõi của mô hình - hàm *logistic*. Ban đầu, hàm logistic được tạo ra bởi những nhà thống kê để đặc tả sự bùng nổ dân số. Hàm này có dạng hình chữ S có thể nhận đầu vào là số thực và có miền giá trị là $(0, L)$. Biểu thức toán học tổng quát của hàm logistic như sau:

$$f(x) = \frac{L}{1 + e^{-k(x-x_0)}} \tag{2.1}$$

- với x_0 là giá trị chính giữa của đường cong logistic;
- k là tỷ lệ tăng của hàm logistic;
- L là giá trị cực đại của hàm logistic.

Mô hình hồi quy logistic thường được sử dụng cho các bài toán phân loại, đặc biệt là phân loại nhị phân, mặc dù trong tên có chứa từ hồi quy ("*regression*"). Nội dung phần tiếp theo sẽ làm rõ lí do cho điều này.

2.2 Bài toán học có giám sát và hàm kích hoạt sigmoid


Cũng giống như *hồi quy tuyến tính* (linear regression) (Freedman, 2009), *hồi quy logistic* được sử dụng để giải bài toán *học có giám sát* (supervised learning) (Russel, Norvig, et al., 2013). Tuy nhiên, *hồi quy logistic* được dùng để giải các bài toán phân loại, còn *hồi quy tuyến tính* được dùng để dự đoán cho các bài toán có giá trị liên tục (như dự đoán giá nhà). Chúng ta sẽ xem xét ví dụ sau để minh họa sự phù hợp hơn của *hồi quy logistic* so với *hồi quy tuyến tính* khi áp dụng vào bài toán phân loại, cụ thể là phân loại nhị phân.

Ví dụ 2.2.1. Xét một tập hợp gồm 14 bộ phim chiếu rạp có thời lượng phim từ 76 tới 186 phút. Từ bảng dữ liệu này, chúng ta sẽ xây dựng một mô hình đánh giá xem một bộ phim được khán giả đánh giá tốt (*G*) hay không tốt (*B*) dựa trên thời lượng phim. Tập dữ liệu được cung cấp như Bảng 2.1.

Bảng 2.1: Dữ liệu đầu vào của Ví dụ 2.2.1

Runtime	Rating
132	G
141	G
88	B
154	G
151	G
102	B
119	B
106	B
102	B
143	G
76	B
168	G
94	B
186	G

Để trực quan hơn, ta biểu diễn dữ liệu đã được cung cấp trên tọa độ không gian 2 chiều như Hình 2.1, trong đó điểm hình vuông biểu diễn phim được đánh giá tốt (G) và điểm hình tròn biểu diễn phim không được đánh giá tốt (B).



Hình 2.1: Đồ thị biểu diễn các điểm dữ liệu trong Bảng 2.1

Trong ví dụ này, đầu vào của mô hình là vector $\mathbf{X}$ tương ứng với thời lượng phim và đầu ra là vector y tương ứng với mức độ đánh giá của khán giả (G/B). Ta khởi tạo vector trọng số $\mathbf{W}$ có chiều dài bằng với vector $\mathbf{X}$ và biến b (bias). Gọi $\hat{y}$ là xác suất một bộ phim được đánh giá tốt khi biết thời lượng phim là ($\hat{y} = P(y = 1|x)$) và $\hat{y}$ nằm trong khoảng $[0, 1]$.


Trong mô hình hồi quy tuyến tính, ta có đầu ra dự đoán là:

$$\hat{y} = z = \mathbf{W}^T \mathbf{X} + b \tag{2.2}$$

Khi áp dụng hồi quy tuyến tính vào bài toán trên chúng ta có thể thu được kết quả như Hình 2.2, trong đó đường thẳng chia cắt các điểm hình tròn và các điểm hình vuông biểu diễn đường hồi quy tuyến tính.

Dễ dàng thấy được 2 vấn đề với kết quả vừa thu được:

- Đường thẳng hồi quy tuyến tính không bị chặn nên có thể cho ra kết quả không nằm trong vùng mong muốn. Như trong Hình 2.2, đường thẳng có thể cho ra giá trị $\hat{y} > 1$ và $\hat{y} < 0$ nên mô hình này chưa hoàn toàn phù hợp cho bài toán này.
- Hồi quy tuyến tính không có khả năng phân loại tốt với dữ liệu bị mất cân bằng. Nếu chúng ta lấy điểm trên đường thẳng này có tung độ bằng 0.5 là điểm ngưỡng phân chia hai lớp (đánh giá tốt nếu $\hat{y} > 0.5$, ngược lại là không tốt). Giả sử có thêm một vài bộ phim dài khoảng 175 phút và được đánh giá tốt. Khi áp dụng mô hình hồi quy tuyến tính, đường thẳng sẽ bị lệch về bên phải (như Hình 2.2) sẽ dẫn đến hiện tượng toàn bộ những bộ phim không tốt sẽ được dự đoán là không tốt, nhưng những bộ phim được đánh giá tốt sẽ được dự đoán là không tốt.




Hình 2.2: Kết quả khi dùng hồi quy tuyến tính

Từ đó, chúng ta sẽ có nhu cầu xây dựng một mô hình khác có khả năng tạo ra đường phân chia tốt hơn so với hồi quy tuyến tính và thỏa mãn các đặc tính sau:

- Là hàm số nhận giá trị thực, bị chặn trong khoảng $(0,1)$;
- Nếu coi điểm (thuộc đường phân chia) có tung độ là 0.5 làm điểm phân chia thì các điểm càng xa điểm này về phía bên trái có giá trị càng gần 0. Ngược lại, các điểm càng xa điểm này về phía phải có giá trị càng gần 1;
- Đường phân chia là một hàm liên tục có thể đạo hàm được, để giúp tìm điểm tối ưu khi sử dụng phương pháp *gradient descent* (sẽ trình bày sau).

Hàm *sigmoid* (Han and Moraga, 1995) (là hàm logistic với $L = 1$, $k = 1$ và $x_0 = 0$) là một hàm số thỏa mãn 3 tính chất nói trên, có phương trình như sau:

$$f(z) = \sigma(z) = \frac{1}{1 + e^{-z}} \quad (2.3)$$



Hình 2.3: Đồ thị hàm sigmoid

Từ phương trình (2.3) và đồ thị Hình 2.3, ta có thể dễ dàng thấy rằng:


$$\begin{cases} \lim_{s \rightarrow -\infty} \sigma(s) = 0 \\ \lim_{s \rightarrow +\infty} \sigma(s) = 1 \end{cases}$$

Vì vậy miền giá trị của hàm sigmoid luôn là $(0, 1)$, rất thích hợp với việc phân loại nhị phân. Ngoài ra, khi đầu vào rất lớn (hoặc rất nhỏ) thì giá trị đầu ra của hàm sigmoid luôn tiến tới tiệm cận giá trị 1 hoặc 0.

Áp dụng hàm sigmoid vào Ví dụ 2.2.1, ta lấy $\mathbf{W}^T \mathbf{X} + b$ làm dữ liệu đầu vào của hàm sigmoid. Phương trình mới của kết quả dự đoán $\hat{y}$:

$$\hat{y} = \sigma(z) = \sigma(\mathbf{W}^T \mathbf{X} + b) \tag{2.4}$$

Với ngưỡng phân loại là 0.5, như kết quả thu được ở Hình 2.4: ta có thể thấy, hồi quy logistic có khả năng phân loại tốt hơn nhiều so với hồi quy tuyến tính.




Hình 2.4: Kết quả khi dùng hồi quy logistic

2.3 Hàm chi phí của hồi quy logistic

Trước khi đi vào nội dung chính của phần này, chúng ta đi qua các khái niệm về *hàm lồi* (convex function) (Bertsekas et al., 2003) và *hàm không lồi* (non-convex function) như sau:

- Hàm f được gọi là lồi trên đoạn $[\alpha, \beta] \subset \mathbb{R}$ nếu $\forall x, y \in [\alpha, \beta]$ và $\forall a, b \geq 0$ thỏa $a + b = 1$ thì $f(ax + by) \geq af(x) + bf(y)$. Nếu f là hàm lồi trên $[\alpha, \beta]$ thì ta có: $\min(f) = \min\{f(\alpha), f(\beta)\}$ nên hàm lồi chỉ có 1 điểm cực tiểu duy nhất (Hình 2.5.a) và đó là điểm mà hàm có giá trị nhỏ nhất trên miền giá trị của nó (*global minimum*) (Stewart et al., 2020);
- Hàm f được gọi là hàm không lồi khi nó không có tính chất lồi. Đồ thị hàm không lồi thường có dạng sóng (Hình 2.5.b) với các điểm cực trị (cực tiểu hay cực đại) (*local optimal*) (Stewart et al., 2020).



Hình 2.5: Đồ thị hàm lồi (a) và đồ thị hàm không lồi (b)

Nhắc lại, trong mô hình hồi quy logistic, phương trình dự đoán là:

$$\hat{y} = \sigma(z) = \sigma(\mathbf{W}^T \mathbf{X} + b)$$

Cũng như những phương pháp khác được dùng để giải các bài toán học có giám sát, quá trình học của mô hình hồi quy logistic là quá trình cập nhật trọng số W . Thế nên hồi quy logistic cũng cần có một *hàm mất mát* (loss function) để đánh giá sự sai biệt giữa kết quả dự đoán $\hat{y}$ và kết quả thực tế y . Ta ký hiệu $\mathcal{L}(\hat{y}, y)$ là hàm mất mát.

Hàm mất mát đơn giản nhất có thể sử dụng là *Least Squared Error* (LSE) (Charnes et al., 1976) có phương trình:

$$\mathcal{L}(\hat{y}, y) = \frac{1}{2}(\hat{y} - y)^2 \quad (2.5)$$

Tuy nhiên, đối với hồi quy logistic, chúng ta không dùng LSE làm hàm mất mát bởi vì phương trình kết quả dự đoán của hồi quy logistic $\hat{y} = \sigma(W^T X + b)$ nên khi đó LSE là một hàm không lồi với nhiều điểm cực tiểu (Hình 2.5.b).

Do LSE không đảm bảo tìm được điểm tối ưu toàn cục khi giải bài toán hồi quy logistic nên chúng ta cần có một hàm mất mát khác cho hồi quy logistic - hàm *cross-entropy* (Murphy, 2012). Phương trình hàm mất mát khi đó sẽ là:

$$\mathcal{L}(\hat{y}, y) = -(y \log \hat{y} + (1 - y) \log (1 - \hat{y})) \quad (2.6)$$

Vì tập giá trị của y là $\{0, 1\}$ nên từ phương trình (2.6), ta có thể thấy:

- Khi $y = 0$: phương trình (2.6) sẽ trở thành $\mathcal{L}(\hat{y}, y) = -\log(1 - \hat{y})$. Trong trường hợp này, nếu kết quả dự đoán $\hat{y}$ càng gần về giá trị 0 thì hàm mất mát cho ra giá trị càng nhỏ và ngược lại, đáp ứng đúng như yêu cầu chúng ta mong muốn.
- Khi $y = 1$: phương trình (2.6) sẽ trở thành $\mathcal{L}(\hat{y}, y) = -\log(\hat{y})$. Trong trường hợp này, nếu kết quả dự đoán $\hat{y}$ càng gần về giá trị 1 thì hàm mất mát cho ra giá trị càng nhỏ và ngược lại, đáp ứng đúng như yêu cầu chúng ta mong muốn.

- Dễ dàng thấy rằng giá trị $\hat{y}$ bằng các giá trị đầu mút (0 và 1) khi và chỉ khi đầu vào của hàm sigmoid là vô cùng, tuy nhiên đây là điều không xảy ra với các phép toán tự nhiên nên ta có thể thấy hàm mất mát luôn cho giá trị có ý nghĩa.

Tiếp theo, chúng ta sẽ giải thích vì sao hàm cross-entropy có thể giúp mô hình hồi quy logistic tìm được điểm tối ưu toàn cục bằng cách chứng minh hàm mất mát dạng cross-entropy cho mô hình hồi quy logistic là một hàm lồi. Nhắc lại, hàm logistic của mô hình hồi quy logistic như sau:

$$h(x^{(i)}) = g(w^T x^{(i)} + b) = \frac{1}{1 + e^{-(w^T x^{(i)} + b)}} \quad (x^{(i)}, w \in \mathbb{R}^D, b \in \mathbb{R}) \quad (2.7)$$

Hàm mất mát của mô hình hồi quy logistic:

$$J(w) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h(x^{(i)})) + (1 - y^{(i)}) \log(1 - h(x^{(i)}))] \quad (2.8)$$

Tính các đạo hàm riêng (partial derivative) của hàm mất mát:

$$\frac{\partial J}{\partial h^{(i)}} = -\frac{1}{m} \cdot \frac{y^{(i)}(1 - h(x^{(i)})) + (y^{(i)} - 1)h(x^{(i)})}{h(x^{(i)})(1 - h(x^{(i)}))} \quad (2.9)$$

$$\frac{\partial h(x^{(i)})}{\partial w^T x^{(i)} + b} = g(w^T x^{(i)} + b)(1 - g(w^T x^{(i)} + b)) = h(x^{(i)})(1 - h(x^{(i)})) \quad (2.10)$$

$$\begin{aligned} \frac{\partial J}{\partial w} &= \sum_{i=1}^m \left[\frac{\partial J}{\partial h^{(i)}} \cdot \frac{\partial h(x^{(i)})}{\partial w^T x^{(i)} + b} \cdot \frac{\partial w^T x^{(i)} + b}{w} \right] \\ &= -\frac{1}{m} \sum_{i=1}^m \left[\frac{y^{(i)}(1 - h(x^{(i)})) + (y^{(i)} - 1)h(x^{(i)})}{h(x^{(i)})(1 - h(x^{(i)}))} h(x^{(i)})(1 - h(x^{(i)})) \circ x^{(i)} \right] \\ &= \frac{1}{m} \sum_{i=1}^m [(h(x^{(i)}) - y^{(i)}) \circ x^{(i)}] \end{aligned} \quad (2.11)$$

$$\text{Ta có } \mathbf{X} = \begin{bmatrix} x^{(1)} \\ x^{(2)} \\ \dots \\ x^{(m)} \end{bmatrix} \in \mathbb{R}^{m \times D}, \mathbf{H} = \begin{bmatrix} h(x^{(1)}) \\ h(x^{(2)}) \\ \dots \\ h(x^{(m)}) \end{bmatrix} \in \mathbb{R}^m, \mathbf{Y} = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \dots \\ y^{(m)} \end{bmatrix} \in \mathbb{R}^m,$$

khi đó công thức đạo hàm bậc 1 theo w là:

$$\frac{\partial J}{\partial w} = \frac{1}{m} \mathbf{X}(\mathbf{H} - \mathbf{Y}) \quad (2.12)$$

và công thức đạo hàm bậc 2 theo w là:

$$\begin{aligned} \frac{\partial^2 J}{\partial w} &= \frac{1}{m} \cdot \frac{\partial \mathbf{X}(\mathbf{H} - \mathbf{Y})}{\partial w} \\ &= \frac{1}{m} \mathbf{X} (\mathbf{H} \circ (1 - \mathbf{H}) \circ \mathbf{X}) \end{aligned} \quad (2.13)$$

Trong đó

$$\mathbf{H} \circ (1 - \mathbf{H}) = \begin{bmatrix} \lambda_1^2 \\ \lambda_2^2 \\ \dots \\ \lambda_m^2 \end{bmatrix} \text{ với } \lambda_i = \sqrt{h(x^{(i)})(1 - h(x^{(i)}))} \geq 0 \quad \forall i = 1 \dots m$$

Lúc này, $\forall \mathbf{z} \in \mathbb{R}^D$ thì:

$$\frac{1}{m} \mathbf{z}^T \mathbf{X} (\mathbf{H} \circ (1 - \mathbf{H}) \circ \mathbf{X}) \mathbf{z} = \frac{1}{m} \begin{bmatrix} \lambda_1 \\ \lambda_2 \\ \dots \\ \lambda_m \end{bmatrix} \circ \mathbf{X} \mathbf{z} \Bigg|^2 \geq 0 \quad (2.14)$$

Điều này có nghĩa rằng $\frac{\partial^2 J}{\partial w}$ là một ma trận nửa xác định dương (PSD). Như vậy có thể kết luận $J(w)$ là một hàm lồi (điều cần chứng minh).

Ở đây, phương trình (2.6) được định nghĩa là hàm mất mát của một điểm dữ liệu đầu vào. Vậy với tập dữ liệu đầu vào có kích thước là m thì sẽ có

được phương trình tổng quát của *hàm chi phí* (cost function) trong mô hình hồi quy logistic như phương trình sau:

$$J(W, b) = \frac{1}{m} \sum_{i=1}^m \mathcal{L}(\hat{y}^{(i)}, y^{(i)}) \tag{2.15}$$

2.4 Sử dụng gradient descent để tìm giá trị tối ưu

Nhắc lại về hàm chi phí của hồi quy logistic:

$$J(w, b) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})] \tag{2.16}$$


$$\text{,với } \hat{y} = \sigma(\mathbf{W}^T \mathbf{X} + b) \text{ và } \sigma(z) = \frac{1}{1 + e^{-z}}$$

Hàm chi phí này cho biết mức độ sai khác giữa giá trị đầu ra được tính toán từ dữ liệu đầu vào ($\hat{y}$) và giá trị đầu ra thật sự của dữ liệu (y) dựa trên giá trị của w và b . Vì vậy, nếu giá trị của chi phí càng nhỏ nghĩa là giá trị tính toán được sẽ càng giống với giá trị thật sự. Bài toán cần giải quyết lúc này là tìm giá trị của w và b sao cho giá trị của hàm chi phí là nhỏ nhất.

Chúng ta sẽ làm điều này bằng cách sử dụng kỹ thuật *gradient descent* (Lemaréchal, 2012). Đây là một phương pháp được sử dụng rộng rãi để tìm kiếm giá trị tối ưu của hàm chi phí. Về lý thuyết, kỹ thuật gradient descent để tìm được giá trị *gần tối ưu* của bất kỳ hàm số nào nếu đó là một hàm khả vi và lồi.

Để hiểu rõ hơn về gradient descent, chúng ta xem xét một ví dụ mang tính trực giác về việc sử dụng phương pháp này để tìm giá trị tối ưu của một hàm số. Trong hình 2.6 là một đồ thị biểu diễn hàm số $J(w)$ có B là điểm tối ưu. Để đến được vị trí B , đầu tiên ta sẽ chọn một điểm bất kì

thuộc đồ thị. Sau đó, ta thay đổi vị trí của điểm đó dựa trên giá trị đạo hàm. Việc cập nhật sẽ được lặp lại cho đến khi điểm ta chọn di chuyển đến vị trí B . Khi đó, ta đã tìm được giá trị tối ưu của hàm $J(w)$.



Hình 2.6: Đồ thị minh họa kỹ thuật gradient descent

Công thức cập nhật của phương pháp gradient descent là:

$$w = w - \alpha \frac{\delta J(w)}{\delta w} \tag{2.17}$$


với α được gọi là *tốc độ học* (learning rate) (Murphy, 2012), dùng để xác định độ dài bước đi mỗi lần cập nhật và giá trị α luôn lớn hơn 0.

Đặc điểm của phương pháp này là quá trình *đi ngược chiều đạo hàm*. Nếu lấy điểm khởi đầu là A , thì khi đó, đạo hàm tại điểm A sẽ có giá trị âm (do $\Delta J(w_A) < 0$ còn $\Delta w_A > 0$). Giá trị w được cập nhật sẽ tăng lên (do $-\alpha \frac{\delta J(w_A)}{\delta w_A} > 0$). Có thể thấy trong trường hợp này rằng điểm A sẽ dời về phía bên phải và “di chuyển” gần hơn đến giá trị tối ưu B .

Trường hợp khác, nếu ta lấy điểm bắt đầu là điểm C , đạo hàm tại điểm C sẽ có giá trị là dương (do $\Delta J(w_C) > 0$ và $\Delta w_C > 0$). Lúc này, giá trị

w sẽ giảm xuống (do $-\alpha \frac{\delta J(w_C)}{\delta w_C} < 0$). Điều đó làm cho điểm C sẽ “di chuyển” về phía bên trái và đến gần hơn với giá trị tối ưu B .


Như vậy, với số lần lặp vừa đủ và chọn giá trị tốc độ học vừa phải, từ một điểm bất kì được chọn trên hàm số, ta đều có thể “di chuyển” về điểm tối ưu của hàm số.




Hình 2.7: Sử dụng gradient descent để tìm giá trị tối ưu

Có thể thấy, khi sử dụng gradient descent, điểm được chọn sẽ dần “tiến về” giá trị tối ưu của hàm số dù bắt đầu ở bất kì vị trí nào của hàm số. Như mô tả trong Hình 2.7, từ điểm A hay C của đồ thị, với số lần lặp vừa đủ và tốc độ học vừa phải, ta sẽ luôn “tiến về” điểm tối ưu B của hàm số.

Để sử dụng gradient descent tìm giá trị tối ưu, cần phải lựa chọn tốc độ học α không quá lớn cũng không quá nhỏ. Nếu lựa chọn giá trị α quá lớn, quá trình lặp khi sử dụng gradient descent sẽ không tiến về giá trị tối ưu nữa mà sẽ “chạy” ra xa điểm tối ưu. Còn nếu giá trị α quá nhỏ, số lần lặp để tới được điểm tối ưu sẽ lớn hơn nhiều. Điều này làm cho thời gian chạy để tìm được điểm tối ưu sẽ lâu hơn rất nhiều.



a) α quá lớn



b) α quá nhỏ

Hình 2.8: Sử dụng gradient descent để tìm giá trị tối ưu ứng với các giá trị α


Hình 2.8a biểu diễn cách tìm điểm tối ưu của hàm số bằng phương pháp gradient descent với giá trị α quá lớn. Với điểm khởi đầu là A , tại đây khi tính đạo hàm và cập nhật hướng về phía bên phải là chính xác, nhưng khi thiết lập giá trị α quá lớn, giá trị mới cập nhật sẽ không phải gần hơn đến điểm tối ưu mà còn bước vượt qua điểm tối ưu này. Nếu quá trình trên được lặp lại với α quá lớn, thì càng ngày ra sẽ đi ra xa điểm tối ưu và sẽ không tìm được kết quả mong đợi.

Ngược lại, Hình 2.8b mô tả trường hợp chọn giá trị α quá nhỏ. Với điểm khởi đầu ngẫu nhiên được chọn là A , sau khi tính toán đạo hàm thì điểm này vẫn di chuyển về vị trí tối ưu nhưng bởi vì giá trị α quá nhỏ nên mỗi lần lặp chỉ có thể di chuyển một khoảng rất ngắn. Vì vậy để điểm A “tiến về” điểm tối ưu cần phải lặp đi lặp lại quá trình này rất nhiều lần. Điều này có nghĩa rằng cần phải tiêu tốn nhiều tài nguyên tính toán và thời gian thực thi nhằm đạt được mục đích.

Vì thế, để giải thuật gradient descent chạy tốt cần phải lựa chọn giá trị α phù hợp sao cho có thể tìm được giá trị tối ưu một cách nhanh nhất và chính xác. Gradient descent cũng chỉ có thể tìm được điểm tối ưu khi hàm số thoả mãn những yêu cầu nhất định - nó phải là khả vi và phải

là hàm lồi. Nếu không thoả mãn 2 yếu tố trên, giải thuật này sẽ không tìm được điểm tối ưu. Nếu hàm số khả vi thì có thể tính được đường đi đến điểm tối ưu bằng phương pháp gradient descent dựa trên giá trị của đạo hàm ($w = w - \alpha \frac{\delta J(w)}{\delta w}$). Còn nếu hàm số không khả vi thì không thể tính được giá trị $\frac{\delta J(w)}{\delta w}$ cũng như việc tìm được điểm tối ưu là không khả thi.


Bên cạnh đó, một yếu tố cần phải được xét đến đó là hàm số phải là hàm lồi, đây là yếu tố quan trọng để xác định xem có thể tìm được điểm tối ưu của hàm số hay không. Vì nếu không là hàm lồi, tùy thuộc vào vị trí khởi tạo mà giá trị tối ưu thu được sau khi sử dụng gradient descent có thể là điểm tối ưu cục bộ, không phải điểm tối ưu toàn cục.



Hình 2.9: Sử dụng gradient descent với hàm số không là hàm lồi

Đồ thị Hình 2.9 là đồ thị biểu diễn của một hàm không lồi. Đối với những hàm số không lồi, ngoài điểm tối ưu toàn cục thì còn có các điểm tối ưu cục bộ. Giả sử lấy điểm khởi đầu là điểm A, sau khi áp dụng phương pháp gradient descent, điểm tối ưu ta tìm được là điểm tối ưu toàn cục là điểm B. Tuy nhiên, nếu điểm khởi đầu là điểm C, thì sau khi áp dụng gradient descent thì điểm tối ưu tìm được sẽ là điểm D, đây không phải là điểm tối ưu toàn cục của hàm số. Vì thế, khi sử dụng gradient descent

với hàm số không là hàm lồi, giá trị tối ưu tìm được có thể không là điểm tối ưu toàn cục. Trên thực tế, khi sử dụng gradient descent chỉ có thể tìm được vị trí gần với điểm tối ưu cục bộ.



Hình 2.10: Kết quả khi áp dụng gradient descent thực tế

Cho đồ thị hàm số như Hình 2.10, điểm khởi đầu là A và sử dụng gradient descent để tìm giá trị tối ưu của hàm số trên. Khi này, kết quả sẽ dần chạy lại gần điểm B . Tuy nhiên, khi đã tiến lại gần B một khoảng nhất định, nếu tiếp tục cập nhật giá trị sau khi áp dụng phương pháp gradient descent, kết quả sẽ vượt qua giá trị tối ưu một khoảng rất nhỏ. Tiếp tục lặp lại các phép tính toán theo phương pháp gradient descent một lần nữa thì sẽ đi qua điểm tối ưu 1 khoảng nhỏ. Và cứ như thế, khi thực hiện gradient descent, kết quả nhận được sẽ dao động một khoảng nhỏ xung quanh giá trị tối ưu B . Tuy nhiên, giá trị sai khác khi dùng gradient descent và giá trị tối ưu là rất nhỏ. Vì thế, kết quả ta thu được sau khi sử dụng gradient descent vẫn rất tốt khi áp dụng vào các bài toán tìm giá trị tối ưu.

Quay trở lại với bài toán tìm giá trị nhỏ nhất của hàm chi phí, hàm số này gồm 2 biến là w và b nên sau mỗi lần lặp của gradient descent cần

phải cập nhật giá trị của cả w và b để thu được giá trị mới nhỏ hơn của hàm chi phí. Có thể thực hiện điều này bằng cách sử dụng đạo hàm riêng từng phần của hàm số theo lần lượt 2 biến.

Công thức hàm chi phí:

$$J(w, b) = \frac{-1}{m} \sum_{i=1}^m y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)}) \tag{2.18}$$

Sau khi tính toán đạo hàm từng phần theo từng biến của hàm chi phí là w và b , kết quả cập nhật của mỗi biến qua mỗi lần lặp của gradient descent là:

$$w = w - \alpha \frac{\delta J(w, b)}{\delta w} \tag{2.19}$$

$$b = b - \alpha \frac{\delta J(w, b)}{\delta b} \tag{2.20}$$


Nếu cập nhật giá trị của w và b với số lần lặp vừa đủ cùng giá trị α vừa phải sẽ tìm ra được giá trị tối ưu của hàm chi phí. Bên cạnh đó, có thể tính được giá trị của $\frac{\delta J(w, b)}{\delta w}$ và $\frac{\delta J(w, b)}{\delta b}$ bằng cách sử dụng *đồ thị tính toán* (computation graph).

2.5 Cách tính đạo hàm riêng dưới góc nhìn đồ thị tính toán

Đồ thị tính toán (computation graph) là một phương pháp giúp tìm đạo hàm riêng theo một biến của hàm số. Hàm số được biểu diễn thành một đồ thị với các đỉnh con là kết quả phép tính của 2 đỉnh cha. Ta sẽ tính giá trị đạo hàm tại mỗi đỉnh của đồ thị bằng cách lấy giá trị xấp xỉ và lan truyền ngược giá trị về đỉnh cha cho đến biến cần tính đạo hàm. Có thể hiểu hơn phương pháp này thông qua ví dụ sau về việc sử dụng đồ thị tính toán để tính đạo hàm riêng.

Ví dụ 2.5.1. Cho hàm số J có phương trình là:

$$J = 5a + 2(b + c) \tag{2.21}$$



Hình 2.11: Sử dụng đồ thị tính toán để biểu diễn hàm số

Hình 2.11 biểu diễn hàm số J cho trước bằng cách sử dụng đồ thị tính toán. Trong đó, hàm số được chia nhỏ thành từng phần và giá trị mỗi phần được tính với các giá trị a, b, c được cho trước. Có thể thực hiện việc chia nhỏ biểu thức (2.21) như sau:

$$t = 5a \tag{2.22}$$

$$u = b + c \tag{2.23}$$

$$v = 2u \tag{2.24}$$

$$J = t + v \tag{2.25}$$

Với mỗi biểu thức nhỏ ở trên là một đỉnh của đồ thị thì sẽ xây dựng được một đồ thị tính toán như Hình 2.11.

Tiếp theo ta sẽ tính đạo hàm tại mỗi đỉnh bằng phương pháp xấp xỉ và lan truyền giá trị ngược lại. Ta bắt đầu với việc tính đạo hàm tại $a = 3$ bằng phương pháp xấp xỉ. Để làm việc này, ta cần chọn một giá trị a_1 sao cho Δa rất nhỏ (0.001). Từ biểu thức (2.22) và (2.25), gán $a_1 = 3.001$, suy ra:

$$t_1 = 5a_1 = 15.005 \quad (2.26)$$

$$J_1 = t_1 + v = 33.005 \quad (2.27)$$

Tính giá trị đạo hàm của J theo a :

$$\frac{\Delta t}{\Delta a} = \frac{t_1 - t}{a_1 - a} = \frac{15.005 - 15}{3.001 - 3} = 5 \quad (2.28)$$

$$\frac{\Delta J}{\Delta t} = \frac{J_1 - J}{t_1 - t} = \frac{33.005 - 33}{15.005 - 15} = 1 \quad (2.29)$$

$$\frac{\Delta J}{\Delta a} = \frac{\Delta J}{\Delta t} \cdot \frac{\Delta t}{\Delta a} = 5 \times 1 = 5 \quad (2.30)$$

Có thể tiến hành xấp xỉ $\frac{\Delta J}{\delta a}$ bằng $\frac{\delta J}{\delta a}$. Từ công thức (2.30), giá trị đạo hàm của J tại $a = 3$ xấp xỉ:

$$\frac{\Delta J}{\Delta a} = 5 \quad (2.31)$$

Tương tự tính giá trị đạo hàm của J tại $b = 4$ và $c = 5$. Với $b = 4$, chọn $b_1 = 4.001$. Từ các phương trình (2.23), (2.24) và (2.25) suy ra:

$$u_1 = b_1 + c = 9.001 \quad (2.32)$$

$$v_1 = 2u_1 = 18.002 \quad (2.33)$$

$$J_1 = t + v_1 = 33.002 \quad (2.34)$$

Tính giá trị đạo hàm của J theo v :

$$\frac{\Delta J}{\Delta v} = \frac{J_1 - J}{v_1 - v} = \frac{33.002 - 33}{18.002 - 18} = 1 \tag{2.35}$$

Sau đó, lan truyền kết quả trên để tính đạo hàm của J theo u dựa trên đạo hàm của J theo v (2.35) và đạo hàm của v theo u :

$$\frac{\Delta v}{\Delta u} = \frac{v_1 - v}{u_1 - u} = \frac{18.002 - 18}{9.001 - 9} = 2 \tag{2.36}$$

$$\frac{\Delta J}{\Delta u} = \frac{\Delta J}{\Delta v} \cdot \frac{\Delta v}{\Delta u} = 1 \times 2 = 2 \tag{2.37}$$

Tiếp tục lan truyền kết quả trên để tính đạo hàm của J theo b dựa trên đạo hàm của J theo u (2.37) và đạo hàm của u theo b :

$$\frac{\Delta u}{\Delta b} = \frac{u_1 - u}{b_1 - b} = \frac{9.001 - 9}{4.001 - 4} = 1 \tag{2.38}$$

$$\frac{\Delta J}{\Delta b} = \frac{\Delta J}{\Delta u} \cdot \frac{\Delta u}{\Delta b} = 2 \times 1 = 2. \tag{2.39}$$

Từ (2.39), giá trị đạo hàm của J tại $b = 4$ xấp xỉ bằng 2.

Cuối cùng, với $c = 5$, chọn $c_1 = 5.001$. Từ các phương trình (2.23), (2.24) và (2.25) suy ra:

$$u_1 = b + c_1 = 9.001 \tag{2.40}$$

$$v_1 = 2u_1 = 18.002 \tag{2.41}$$

$$J_1 = t + v_1 = 33.002 \tag{2.42}$$

Tính giá trị đạo hàm của J theo v :

$$\frac{\Delta J}{\Delta v} = \frac{J_1 - J}{v_1 - v} = \frac{33.002 - 33}{18.002 - 18} = 1 \tag{2.43}$$

Lan truyền kết quả trên để tính đạo hàm của J theo u dựa trên đạo hàm của J theo v (2.43) và đạo hàm của v theo u :

$$\frac{\Delta v}{\Delta u} = \frac{v_1 - v}{u_1 - u} = \frac{18.002 - 18}{9.001 - 9} = 2 \quad (2.44)$$

$$\frac{\Delta J}{\Delta u} = \frac{\Delta J}{\Delta v} \cdot \frac{\Delta v}{\Delta u} = 1 \times 2 = 2 \quad (2.45)$$

Tiếp tục với việc lan truyền kết quả trên để tính đạo hàm của J theo c dựa trên đạo hàm của J theo u (2.45) và đạo hàm của u theo c :

$$\frac{\Delta u}{\Delta c} = \frac{u_1 - u}{c_1 - c} = \frac{9.001 - 9}{5.001 - 5} = 1 \quad (2.46)$$

$$\frac{\Delta J}{\Delta c} = \frac{\Delta J}{\Delta u} \cdot \frac{\Delta u}{\Delta c} = 2 \times 1 = 2 \quad (2.47)$$

Từ kết quả (2.47), có thể đưa ra kết luận rằng giá trị đạo hàm của J tại $c = 5$ xấp xỉ bằng 2.

Khi tính đạo hàm ở từng bước như Ví dụ 2.5.1, có thể thay việc tính xấp xỉ bằng cách dùng công thức đạo hàm để tính giá trị đạo hàm trực tiếp với các hàm số khả vi. Sau đây là cách sử dụng phương pháp này để tính đạo hàm khi thực hiện quá trình gradient descent. Hàm mất mát của hồi quy logistic với giả sử vector nhập x có 2 đặc trưng (*feature*) (tức là x có số chiều là 2):


$$\mathcal{L}(a, y) = -(y \log(a) + (1 - y) \log(1 - a)) \quad (2.48)$$

trong đó:

$$a = \hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}} \quad (2.49)$$

$$z = w^T x + b \quad (2.50)$$

Tương tự như Ví dụ 2.5.1, có thể dễ dàng vẽ được đồ thị tính toán của hàm số (2.48) như Hình 2.12.



Hình 2.12: Đồ thị tính toán hàm mất mát của hồi quy logistic

Tính đạo hàm của $\mathcal{L}$ theo a từ phương trình (2.48):

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial a} &= - \left(y \frac{1}{a} + (1 - y) \frac{-1}{1 - a} \right) = \frac{1 - y}{1 - a} - \frac{y}{a} \\ &= \frac{a(1 - y) - y(1 - a)}{a(1 - a)} = \frac{a - y}{a(1 - a)} \end{aligned} \tag{2.51}$$

Sau đó, lan truyền kết quả trên để tính đạo hàm của $\mathcal{L}$ theo z dựa trên đạo hàm của $\mathcal{L}$ theo a từ kết quả (2.51) và đạo hàm của a theo z :

$$\begin{aligned} \frac{\partial a}{\partial z} &= \frac{0(1 + e^{-z}) - (-e^{-z})1}{(1 + e^{-z})^2} = \frac{e^{-z}}{(1 + e^{-z})^2} \\ &= \frac{1}{1 + e^{-z} \frac{e^{-z}}{1 + e^{-z}}} = \frac{1}{1 + e^{-z}} \cdot \frac{1 + e^{-z} - 1}{1 + e^{-z}} \\ &= a(1 - a) \end{aligned}$$

$$\frac{\partial \mathcal{L}}{\partial z} = \frac{\partial \mathcal{L}}{\partial a} \cdot \frac{\partial a}{\partial z} = \frac{a - y}{a(1 - a)} a(1 - a) = a - y \tag{2.52}$$

Tiếp theo là lan truyền kết quả trên để tính đạo hàm của $\mathcal{L}$ theo w_1 , w_2 , b dựa trên đạo hàm của $\mathcal{L}$ theo z từ (2.52) và đạo hàm của z theo w_1 , w_2 , b :

$$\begin{aligned}\frac{\partial z}{\partial w_1} &= x_1 \\ \frac{\partial \mathcal{L}}{\partial w_1} &= \frac{\partial \mathcal{L}}{\partial z} \cdot \frac{\partial z}{\partial w_1} = (a - y)x_1\end{aligned}\tag{2.53}$$

$$\begin{aligned}\frac{\partial z}{\partial w_2} &= x_2 \\ \frac{\partial \mathcal{L}}{\partial w_2} &= \frac{\partial \mathcal{L}}{\partial z} \cdot \frac{\partial z}{\partial w_2} = (a - y)x_2\end{aligned}\tag{2.54}$$

$$\begin{aligned}\frac{\partial z}{\partial b} &= 1 \\ \frac{\partial \mathcal{L}}{\partial b} &= \frac{\partial \mathcal{L}}{\partial z} \cdot \frac{\partial z}{\partial b} = (a - y)\end{aligned}\tag{2.55}$$

Có thể suy ra công thức đồ thị tính toán cho hàm mất mát từ (2.53), (2.54), (2.55) là:

$$w_1 = w_1 - \alpha \frac{\partial \mathcal{L}}{\partial w_1} = w_1 - \alpha(a - y)x_1\tag{2.56}$$

$$w_2 = w_2 - \alpha \frac{\partial \mathcal{L}}{\partial w_2} = w_2 - \alpha(a - y)x_2\tag{2.57}$$

$$b = b - \alpha \frac{\partial \mathcal{L}}{\partial b} = b - \alpha(a - y)\tag{2.58}$$

Hàm chi phí trong trường hợp này là trung bình cộng các hàm mất mát của mỗi mẫu dữ liệu:

$$J(w, b) = \frac{1}{m} \sum_{i=1}^m \mathcal{L}(a^i, y^i)\tag{2.59}$$

Từ đó, có thể tính được gradient descent của hàm chi phí bằng cách tính tổng gradient descent các hàm mất mát của dữ liệu từ các kết quả tính toán (2.56), (2.57), (2.58), (2.59):

$$\begin{aligned} w_1 &= w_1 - \alpha \frac{\partial J(w, b)}{\partial w_1} \\ &= w_1 - \frac{\alpha}{m} \sum_{i=1}^m \frac{\partial \mathcal{L}(a^i, y^i)}{\partial w_1} = w_1 - \frac{\alpha}{m} \sum_{i=1}^m (a^i - y^i) x_1^i \end{aligned} \quad (2.60)$$

$$\begin{aligned} w_2 &= w_2 - \alpha \frac{\partial J(w, b)}{\partial w_2} \\ &= w_2 - \frac{\alpha}{m} \sum_{i=1}^m \frac{\partial \mathcal{L}(a^i, y^i)}{\partial w_2} = w_2 - \frac{\alpha}{m} \sum_{i=1}^m (a^i - y^i) x_2^i \end{aligned} \quad (2.61)$$

$$\begin{aligned} b &= b - \alpha \frac{\partial J(w, b)}{\partial b} \\ &= b - \frac{\alpha}{m} \sum_{i=1}^m \frac{\partial \mathcal{L}(a^i, y^i)}{\partial b} = b - \frac{\alpha}{m} \sum_{i=1}^m (a^i - y^i) \end{aligned} \quad (2.62)$$

Một cách tổng quát hơn, với một dữ liệu gồm n đặc trưng thì gradient descent là:

$$\begin{aligned} w_1 &= w_1 - \frac{\alpha}{m} \sum_{i=1}^m (a^i - y^i) x_1^i \\ w_2 &= w_2 - \frac{\alpha}{m} \sum_{i=1}^m (a^i - y^i) x_2^i \\ &\vdots \\ w_n &= w_n - \frac{\alpha}{m} \sum_{i=1}^m (a^i - y^i) x_n^i \\ b &= b - \frac{\alpha}{m} \sum_{i=1}^m (a^i - y^i) \end{aligned}$$

Phương pháp cập nhật trọng số bằng cách tính đạo hàm xuất phát từ đỉnh cuối của đồ thị tính toán cho đến các nút lá (ứng với các trọng số cần tính toán) như vậy gọi là phương pháp *lan truyền ngược* (back propagation) (Voleti, 2021).

2.6 Tổng kết phương pháp hồi quy logistic

Như vậy phương pháp hồi quy logistic sẽ tìm bộ trọng số phù hợp nhất để tối ưu hàm chi phí (tức là bộ trọng số tìm được sẽ làm cho giá trị hàm chi phí đạt giá trị nhỏ nhất với bộ dữ liệu nhập cho trước). Kỹ thuật hồi quy logistic làm được điều này bằng cách sử dụng hai kỹ thuật gradient descent và lan truyền ngược. Đây cũng là hai kỹ thuật nền tảng cho một mạng nơ-ron nhân tạo. Giải thuật Algorithm 1 sau trình bày mã giả của giải thuật hồi quy logistic.

Tổng quát, xét trên một tập dữ liệu gồm m dữ liệu và mỗi dữ liệu gồm n đặc trưng. Bước đầu tiên, ta cần phải khai báo các biến cần thiết sau: các $w_1, w_2, \dots, w_n$ lần lượt là các trọng số của mỗi đặc trưng thuộc dữ liệu; b là giá trị *bias* cần thiết được thêm vào để đảm bảo hàm có thể học được; giá trị num_iter là số lần lặp để tìm được giá trị tối ưu của hàm chi phí (đây là giá trị ta có thể tùy chỉnh bằng cách gán 40, 50 hay 500 thậm chí đến 10000 tùy thuộc vào số lần lặp cần thiết để tìm được giá trị tối ưu của hàm chi phí); $alpha$ là tốc độ học được thiết lập cho gradient descent (giá trị này không nên quá nhỏ hoặc quá lớn).

Bước tiếp theo là tính gradient descent của hàm chi phí bằng cách lặp lại việc cập nhật các trọng số với số lần lặp num_iter cho trước. Trong mỗi lần lặp, cần phải khởi tạo giá trị của hàm chi phí J , các giá trị đạo hàm của J theo $w_1, w_2, \dots, w_n$ là $dw_1, dw_2, \dots, dw_n$ và đạo hàm của J theo b là w_b .

Thuật toán sẽ được tính toán qua từng mẫu dữ liệu trong tập dữ liệu cho trước và tính giá trị đầu ra. Tiếp đến sự sai biệt giữa giá trị tính toán

và giá trị thực tế dựa trên cross-entropy sẽ được ước lượng và thêm kết quả vào hàm chi phí. Sau khi chạy qua hết tập dữ liệu, thuật toán tính giá trị đạo hàm của J theo từng trọng số theo công thức được suy ra từ phần trước. Cuối cùng thuật toán sẽ cập nhật giá trị các trọng số dựa trên đạo hàm của chúng theo gradient descent. Quá trình trên sẽ được lặp lại cho đến khi tìm được giá trị tối ưu của hàm chi phí và thu được bộ trọng số thoả mãn yêu cầu.

Algorithm 1: Logistic regression

$num_iter = 500, w_1 = 0, w_2 = 0, \dots, w_n = 0, b = 0, alpha = 0.1$

for $i \leftarrow 1$ **to** $range(num_iter)$ **do**

$J = 0, dw_1 = 0, dw_2 = 0, \dots, dw_n = 0, db = 0$

for $j \leftarrow 1$ **to** m **do**

$z = w_1 * x_{j1} + w_2 * x_{j2} + \dots + w_n * x_{jn} + b$

$a = 1 / (1 + e^{(-z)})$

$J += -(y_j * \log(a_j) + (1 - y_j) * \log(1 - a_j))$

$dz = a_j - y_j$

$dw_1 += dz * x_{j1}$

$dw_2 += dz * x_{j2}$

 ...

$dw_n += dz * x_{jn}$

$db += dz$

$J /= m$

$dw_1 /= m$

$dw_2 /= m$

 ...

$dw_n /= m$

$db /= m$

$w_1 = w_1 - alpha * dw_1$

$w_2 = w_2 - alpha * dw_2$

 ...

$w_n = w_n - alpha * dw_n$

$b = b - alpha * db$

2.7 Kết chương

Qua chương này, chúng ta đã tìm hiểu quá trình hồi quy logistic được sử dụng để tìm bộ trọng số giúp tối ưu hàm lượng giá trong một bài toán học có giám sát. Để làm được điều này, kỹ thuật hồi quy logistic dựa trên hai kỹ thuật quan trọng là gradient descent và lan truyền ngược. Đây cũng là hai kỹ thuật cơ bản của một mạng nơ-ron sẽ được trình bày trong chương sau.

2.8 Bài tập

Bài tập 2.8.1. Bảng 2.2 mô tả cân nặng và giới tính của một số trẻ sơ sinh. Hãy sử dụng mô hình hồi quy logistic $h\theta(x) = g(\theta_0 + \theta_1 x_1)$ để giải bài toán phân loại Nam (M) và Nữ (F) dựa theo cân nặng, với x_1 là vector cân nặng những bé sơ sinh trong tập dữ liệu, g là hàm sigmoid, và θ_0, θ_1 là hai trọng số cần phải học. Giả sử $y = 0$ khi đó là bé nữ và $y = 1$ khi đó là bé nam, tốc độ học $\alpha = 0.2$ và giá trị khởi tạo của θ_0, θ_1 là 0.5, hàm mất mát là hàm cross-entropy. Với tập dữ liệu training như Bảng 2.2 và sử dụng mô hình hồi quy logistic để cập nhật trọng số θ_0 và θ_1 , hãy cho biết giá trị của hai trọng số θ_0 và θ_1 sau 2 lần lặp?

Bảng 2.2: Dữ liệu đầu vào của Bài tập 2.8.1

Cân nặng (kg)	Giới tính
2.4	Nữ
3.3	Nam
3.2	Nam
2.5	Nữ

Bài tập 2.8.2. Cho phương trình $J = 3a + 2(4b + 5cd)$

Hãy vẽ đồ thị tính toán của phương trình trên và tính đạo hàm của J tại từng biến a, b, c, d với $a = 2, b = 3, c = 4, d = 5$.