

Điểm quan trọng là hai yếu tố này thường đối kháng lẫn nhau: Nếu ta làm cây mạnh hơn (ví dụ: dùng nhiều đặc trưng), thì độ tương quan giữa các cây thường tăng. Ngược lại, nếu ta giảm độ tương quan (ví dụ: chọn ít đặc trưng hơn), thì độ mạnh của từng cây có thể giảm. Cơ chế lấy mẫu lặp lại và lựa chọn đặc trưng ngẫu nhiên cho từng cây chính là cách để mô hình rừng ngẫu nhiên có thể đạt được cả hai yếu tố này.

8.4 Hồi quy tuyến tính


Trong hai chương trước chúng ta đã tìm hiểu về cây quyết định và rừng ngẫu nhiên, hai mô hình điển hình giải quyết tác vụ phân loại. Trong chương này, chúng ta sẽ tìm hiểu một mô hình đơn giản nhất cho tác vụ hồi quy, đó là mô hình hồi quy tuyến tính (linear regression).

Đối với tác vụ phân loại, chúng ta đã làm quen với tập dữ liệu dự đoán ngày mưa/nắng từ dữ liệu thời tiết (nhiệt độ, độ ẩm). Bây giờ, chúng ta hãy nhìn bài toán khác đi một chút: thay vì dự đoán trời có mưa hay không, chúng ta hãy dự đoán chỉ số nhiệt, một con số thể hiện mức độ nóng bức mà con người cảm nhận được. Bảng 8.3 trình bày dữ liệu quá khứ mà chúng ta thu thập được.

Bảng 8.3: Dữ liệu cho bài toán dự đoán chỉ số nhiệt.

Ngày (i)	Nhiệt độ (x_i^1)	Độ ẩm (x_i^2)	Chỉ số nhiệt thực tế (y_i)
D1	24	29	26
D2	25	32	37
D3	26	34	40
D4	27	40	49
D5	28	41	54
D6	28	50	64
D7	29	55	88
D8	31	57	102
D9	32	69	122
D10	33	78	130

Hình 8.5 minh họa trực quan các điểm dữ liệu được thu thập trong quá khứ.



Hình 8.5: Biểu diễn mối tương quan giữa nhiệt độ, độ ẩm và chỉ số nhiệt.

Từ hình này, ta có thể nhận thấy một xu hướng rõ ràng: khi nhiệt độ và độ ẩm tăng, chỉ số nhiệt cũng có xu hướng tăng theo. Dựa trên quan sát đó, ta giả định rằng mối quan hệ giữa chỉ số nhiệt và các dữ liệu đầu vào (nhiệt độ, độ ẩm) có thể được xấp xỉ bằng một hàm tuyến tính. Vì vậy, ta sử dụng một hàm f dạng tuyến tính để mô hình hóa mối quan hệ này:

$$y_i = f(x_i^1, x_i^2) = \theta_0 + \theta_1 x_i^1 + \theta_2 x_i^2,$$

trong đó, θ_0 được gọi là hệ số chệch (bias hay intercept), còn (θ_1, θ_2) là các trọng số của mô hình f . Mỗi bộ tham số $(\theta_0, \theta_1, \theta_2)$ khác nhau sẽ tương ứng với một mô hình khác nhau. Chẳng hạn, nếu θ_1 quá lớn, mô hình sẽ coi nhiệt độ là yếu tố đặc biệt quan trọng, trong khi ảnh hưởng của độ ẩm trở nên tương đối nhỏ. Tương tự, giá trị của θ_0 cho phép mô hình điều chỉnh mức dự đoán cơ sở ngay cả khi các biến đầu vào bằng 0. Vậy bộ tham số nào là bộ tham số tốt nhất?

Tìm bộ trọng số tối ưu cho mô hình. Như đã trình bày trong Chương 7, để tìm được bộ trọng số tối ưu cho mô hình, ta xây dựng một hàm mất mát nhằm lượng hóa mức độ sai lệch giữa dự đoán của mô hình và giá trị thực tế. Quá trình huấn luyện khi đó sẽ tìm bộ tham số $(\theta_0, \theta_1, \theta_2)$ sao cho hàm mất mát $\mathcal{L}$ đạt giá trị nhỏ nhất. Đối với hồi quy tuyến tính, hàm mất mát được sử dụng là hàm MSE (Chương 5):

$$\mathcal{L} = \frac{1}{n} \sum_{i=1}^n (y_i - f(\mathbf{x}_i))^2,$$

với n là số lượng mẫu trong tập huấn luyện. Bộ tham số tối ưu là nghiệm của bài toán tối ưu sau:

$$(\theta_0^*, \theta_1^*, \theta_2^*) = \arg \min_{\theta_0, \theta_1, \theta_2} \sum_{i=1}^n \left(y_i - (\theta_0 + \theta_1 x_i^1 + \theta_2 x_i^2) \right)^2. \quad (8.7)$$

Đây là một bài toán tối ưu lồi và có lời giải tường minh (xem Chương 6). Nếu viết dưới dạng ma trận, nghiệm tối ưu của bài toán được biểu diễn bởi công thức:

$$\boldsymbol{\theta}^* = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y},$$

trong đó:

$$\boldsymbol{\theta} = \begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} 1 & x_1^1 & x_1^2 \\ 1 & x_2^1 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n^1 & x_n^2 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

Tuy nhiên, bên cạnh cách tìm nghiệm tường minh, ta cũng có thể sử dụng phương pháp giảm dần đạo hàm (Chương 6) để tìm lời giải xấp xỉ. Trong trường hợp này,

công thức cập nhật tham số của mô hình là:

$$\theta_{\text{new}} = \theta_{\text{old}} - \eta \nabla_{\theta} \mathcal{L}, \quad \mathcal{L} = \frac{1}{n} \sum_{i=1}^n \left(y_i - (\theta_0 + \theta_1 x_i^1 + \theta_2 x_i^2) \right)^2, \quad (8.8)$$

trong đó η là tốc độ học (learning rate). Đạo hàm của hàm mất mát theo hệ số chệch θ_0 và các hệ số trọng số θ_j ($j = 1, 2$) có dạng:

$$\frac{\partial \mathcal{L}}{\partial \theta_0} = -\frac{2}{n} \sum_{i=1}^n (y_i - \hat{y}_i), \quad \text{và} \quad \frac{\partial \mathcal{L}}{\partial \theta_j} = -\frac{2}{n} \sum_{i=1}^n (y_i - \hat{y}_i) x_i^j. \quad (8.9)$$

Do đó, quy tắc cập nhật chi tiết cho từng tham số tại mỗi bước được xác định bởi:

$$\theta_0 \leftarrow \theta_0 + \frac{2}{n} \eta \sum_{i=1}^n (y_i - \hat{y}_i), \quad \theta_j \leftarrow \theta_j + \frac{2}{n} \eta \sum_{i=1}^n (y_i - \hat{y}_i) x_i^j \quad (\text{với } j = 1, 2). \quad (8.10)$$

Tổng quát hóa. Trong trường hợp mỗi điểm dữ liệu $\mathbf{x}_i$ có m đặc trưng đầu vào $(x_i^1, \dots, x_i^m)$, mô hình hồi quy tuyến tính tổng quát có dạng:

$$y_i = \theta_0 + \sum_{j=1}^m \theta_j x_i^j.$$

Khi đó, nếu đặt:

$$\tilde{\mathbf{x}}_i = (1, x_i^1, \dots, x_i^m)^T,$$

thì nghiệm tường minh của bài toán tối ưu có thể được viết gọn dưới dạng:

$$\theta^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y},$$

với $\mathbf{X}$ là ma trận chứa toàn bộ các mẫu dữ liệu sau khi bổ sung thêm cột hằng số 1 để mô hình hóa hệ số chệch θ_0 . Tương tự, công thức cập nhật tham số theo phương pháp suy giảm độ dốc có dạng:

$$\theta_{\text{new}} = \theta_{\text{old}} - \eta \nabla_{\theta} \mathcal{L}, \quad \mathcal{L} = \frac{1}{n} \sum_{i=1}^n \left(y_i - \left(\theta_0 + \sum_{j=1}^m \theta_j x_i^j \right) \right)^2.$$

Thay công thức đạo hàm riêng vào, ta có:

$$\begin{aligned} \theta_0 &\leftarrow \theta_0 + \frac{2}{n} \eta \sum_{i=1}^n \left(y_i - \left(\theta_0 + \sum_{j=1}^m \theta_j x_i^j \right) \right) = \theta_0 + \frac{2}{n} \eta \sum_{i=1}^n (y_i - \hat{y}_i), \\ \theta_j &\leftarrow \theta_j + \frac{2}{n} \eta \sum_{i=1}^n \left(y_i - \left(\theta_0 + \sum_{l=1}^m \theta_l x_i^l \right) \right) x_i^j = \theta_j + \frac{2}{n} \eta \sum_{i=1}^n (y_i - \hat{y}_i) x_i^j \end{aligned}$$

Trong thực tế, hệ số 2 thường được gộp vào hệ số học η để biểu thức trở nên gọn hơn.

8.5 Mô hình hồi quy logistic

8.5.1 Tại sao chúng ta cần hồi quy logistic

Trong chương trước, chúng ta đã tìm hiểu mô hình hồi quy tuyến tính, một phương pháp cho phép dự đoán các giá trị đầu ra liên tục trên toàn bộ trục số thực. Tuy nhiên, trong nhiều bài toán thực tế, đầu ra không phải là một giá trị bất kỳ, mà bị ràng buộc trong một khoảng nhất định. Chẳng hạn, ta có thể muốn dự đoán xác suất một email là thư rác, hoặc khả năng một bệnh nhân mắc một căn bệnh nào đó. Trong những trường hợp này, đầu ra là một số thực dương nằm trong khoảng $[0, 1]$. Do đó, mô hình hồi quy tuyến tính không còn phù hợp, vì nó không đảm bảo giá trị dự đoán nằm trong khoảng này. Để giải quyết vấn đề này, ta sử dụng mô hình hồi quy logistic (logistic regression), vốn được thiết kế để dự đoán các xác suất, nhận giá trị trong khoảng $[0, 1]$.

8.5.2 Ý tưởng của hồi quy logistic

Ý tưởng trung tâm của hồi quy logistic là không mô hình hóa trực tiếp xác suất $p(\mathbf{x})$, mà mô hình hóa một phép biến đổi của xác suất, có dải giá trị là toàn bộ miền số thực. Để thấy vì sao điều này lại hợp lý, trước hết ta xét đại lượng sau:

$$\frac{p(\mathbf{x})}{1 - p(\mathbf{x})}. \quad (8.11)$$

Đại lượng này được gọi là odds. Nếu $p(\mathbf{x})$ là xác suất xảy ra sự kiện, thì $1 - p(\mathbf{x})$ là xác suất sự kiện không xảy ra, và odds biểu diễn tỷ số giữa hai khả năng đó. Ví dụ, nếu $p(\mathbf{x}) = 0.8$, thì odds bằng $0.8/0.2 = 4$, nghĩa là sự kiện xảy ra có khả năng cao gấp bốn lần sự kiện không xảy ra. Ở đây, chúng ta có thể thấy, biểu thức sau khi biến đổi $\frac{p(\mathbf{x})}{1 - p(\mathbf{x})}$ đã có dải giá trị rộng hơn (không bị giới hạn bởi $[0, 1]$). Tuy nhiên, odds chỉ nhận giá trị dương, nên vẫn chưa tiện để mô hình hóa bằng một hàm tuyến tính. Vì vậy, ta lấy log của odds và thu được đại lượng $\log \frac{p(\mathbf{x})}{1 - p(\mathbf{x})}$ gọi là log-odds hay logit. Ưu điểm rất lớn của logit là nó có thể nhận mọi giá trị thực từ $-\infty$ đến $+\infty$.

Tới đây, chúng ta có thể sử dụng tư tưởng của hồi quy tuyến tính. Để biểu diễn công thức một cách gọn gàng, ta sử dụng kỹ thuật mở rộng vector (bias trick) bằng cách định nghĩa vector đầu vào mở rộng $\tilde{\mathbf{x}} = [1, \mathbf{x}^\top]^\top$ và vector tham số mở rộng tương ứng $\tilde{\boldsymbol{\theta}} = [\theta_0, \boldsymbol{\theta}^\top]^\top$. Khi đó, giả định logit là một hàm tuyến tính của vector

đầu vào mở rộng trở nên khả thi:

$$\log \frac{p(\mathbf{x})}{1-p(\mathbf{x})} = \tilde{\boldsymbol{\theta}}^\top \tilde{\mathbf{x}}. \quad (8.12)$$


Từ công thức trên, ta có thể giải ngược ra $p(\mathbf{x})$ như sau:

$$\begin{aligned} \log \frac{p(\mathbf{x})}{1-p(\mathbf{x})} = \tilde{\boldsymbol{\theta}}^\top \tilde{\mathbf{x}} &\Rightarrow \frac{p(\mathbf{x})}{1-p(\mathbf{x})} = e^{\tilde{\boldsymbol{\theta}}^\top \tilde{\mathbf{x}}} \\ &\Rightarrow p(\mathbf{x}) = \frac{e^{\tilde{\boldsymbol{\theta}}^\top \tilde{\mathbf{x}}}}{1 + e^{\tilde{\boldsymbol{\theta}}^\top \tilde{\mathbf{x}}}} = \frac{1}{1 + e^{-\tilde{\boldsymbol{\theta}}^\top \tilde{\mathbf{x}}}}. \end{aligned} \quad (8.13)$$

Hàm này được gọi là hàm logistic hay hàm sigmoid (Chương 5). Nó ánh xạ toàn bộ trục số thực vào khoảng $(0, 1)$, vì thế rất phù hợp để biểu diễn xác suất. Về trục quan, nếu tích vô hướng $\tilde{\boldsymbol{\theta}}^\top \tilde{\mathbf{x}}$ là một số dương lớn, thì $e^{-\tilde{\boldsymbol{\theta}}^\top \tilde{\mathbf{x}}}$ rất nhỏ, nên $p(\mathbf{x})$ tiến gần đến 1. Ngược lại, nếu $\tilde{\boldsymbol{\theta}}^\top \tilde{\mathbf{x}}$ là một số rất âm, thì $e^{-\tilde{\boldsymbol{\theta}}^\top \tilde{\mathbf{x}}}$ rất lớn, nên $p(\mathbf{x})$ tiến gần đến 0. Khi $\tilde{\boldsymbol{\theta}}^\top \tilde{\mathbf{x}} = 0$, ta có:

$$p(\mathbf{x}) = \frac{1}{1 + e^0} = \frac{1}{2}. \quad (8.14)$$

Hình 8.6 minh họa sự khác nhau giữa hồi quy tuyến tính và hồi quy logistic.



Hình 8.6: So sánh sự khác nhau giữa hồi quy tuyến tính và hồi quy logistic.

8.5.3 Khai triển toán học của hồi quy logistic

Log-likelihood. Để ước lượng vector trọng số mở rộng $\tilde{\boldsymbol{\theta}}$, ta sử dụng phương pháp ước lượng hợp lý cực đại (MLE) (Chương 5). Giả sử tập dữ liệu gồm n quan sát độc lập $\{(\mathbf{x}_i, y_i)\}_{i=1}^n, y_i \in \{0, 1\}$. Theo giả định Bernoulli (Chương 5), xác suất để quan sát thứ i có nhãn y_i là:

$$\Pr(y_i | \tilde{\mathbf{x}}_i) = p(\tilde{\mathbf{x}}_i)^{y_i} (1 - p(\tilde{\mathbf{x}}_i))^{1-y_i}. \quad (8.15)$$

Giả sử các quan sát độc lập với nhau, hàm hợp lý của toàn bộ dữ liệu là tích các xác suất riêng lẻ:

$$L(\tilde{\boldsymbol{\theta}}) = \prod_{i=1}^n p(\tilde{\mathbf{x}}_i)^{y_i} (1 - p(\tilde{\mathbf{x}}_i))^{1-y_i}. \quad (8.16)$$

Lấy log để biến tích thành tổng, ta nhận được log-likelihood:

$$\ell(\tilde{\theta}) = \log L(\tilde{\theta}) = \sum_{i=1}^n [y_i \log p(\tilde{\mathbf{x}}_i) + (1 - y_i) \log(1 - p(\tilde{\mathbf{x}}_i))]. \quad (8.17)$$

Công thức này có ý nghĩa như sau:

- nếu $y_i = 1$, phần $y_i \log p(\tilde{\mathbf{x}}_i)$ giữ lại và khuyến khích $p(\tilde{\mathbf{x}}_i)$ lớn,
- nếu $y_i = 0$, phần $(1 - y_i) \log(1 - p(\tilde{\mathbf{x}}_i))$ giữ lại và khuyến khích $p(\tilde{\mathbf{x}}_i)$ nhỏ.

Thay hàm sigmoid mở rộng:

$$p(\tilde{\mathbf{x}}_i) = \frac{e^{\tilde{\theta}^\top \tilde{\mathbf{x}}_i}}{1 + e^{\tilde{\theta}^\top \tilde{\mathbf{x}}_i}} \quad (8.18)$$

vào phương trình (8.17) và thực hiện một số phép biến đổi, ta có:

$$\begin{aligned} \ell(\tilde{\theta}) &= \sum_{i=1}^n \left[y_i ((\tilde{\theta}^\top \tilde{\mathbf{x}}_i) - \log(1 + e^{\tilde{\theta}^\top \tilde{\mathbf{x}}_i})) + (1 - y_i) (-\log(1 + e^{\tilde{\theta}^\top \tilde{\mathbf{x}}_i})) \right] \\ &= \sum_{i=1}^n \left[y_i (\tilde{\theta}^\top \tilde{\mathbf{x}}_i) - \log(1 + e^{\tilde{\theta}^\top \tilde{\mathbf{x}}_i}) \right]. \end{aligned} \quad (8.19)$$

Đây là dạng log-likelihood thường dùng trong lý thuyết và thực hành.

Đạo hàm và điều kiện cực trị. Việc tìm bộ trọng số tối ưu của mô hình hồi quy logistic tương đương với việc cực đại hóa log-likelihood. Từ phương trình (8.19), ta lấy đạo hàm (gradient) của hàm mục tiêu theo toàn bộ vector tham số mở rộng $\tilde{\theta}$:

$$\nabla_{\tilde{\theta}} \ell = \sum_{i=1}^n \left[y_i \tilde{\mathbf{x}}_i - \frac{e^{\tilde{\theta}^\top \tilde{\mathbf{x}}_i}}{1 + e^{\tilde{\theta}^\top \tilde{\mathbf{x}}_i}} \cdot \tilde{\mathbf{x}}_i \right] = \sum_{i=1}^n (y_i - p(\tilde{\mathbf{x}}_i)) \tilde{\mathbf{x}}_i.$$

Công thức này có ý nghĩa như sau. Đại lượng $y_i - p(\tilde{\mathbf{x}}_i)$ là sai lệch giữa nhãn thực và xác suất dự đoán. Nếu mô hình dự đoán xác suất quá thấp cho một điểm có nhãn 1, thì sai lệch dương và gradient sẽ điều chỉnh tham số theo hướng làm tăng xác suất. Nếu mô hình dự đoán xác suất quá cao cho một điểm có nhãn 0, thì sai lệch âm và đạo hàm sẽ điều chỉnh theo hướng ngược lại. Vì vậy, hồi quy logistic có thể được hiểu là một quá trình liên tục hiệu chỉnh xác suất dự đoán để gần với nhãn quan sát.

Tuy nhiên, hệ phương trình vector $\nabla_{\tilde{\theta}} \ell(\tilde{\theta}) = \mathbf{0}$ là phi tuyến, không có nghiệm dạng đóng. Vì vậy, ta có thể tìm trọng số tối ưu thông qua phương pháp giảm dần đạo hàm, hoặc dựa trên các phương pháp số tìm nghiệm gần đúng, như sau.

Tìm nghiệm gần đúng bằng phương pháp Newton-Raphson. Một trong những phương pháp kinh điển để tìm nghiệm gần đúng cho bài toán hồi quy logistic là phương pháp Newton-Raphson. Phương pháp này tiếp cận bằng cách cực tiểu (hoặc cực đại) hóa một xấp xỉ parabol của hàm số tại điểm hiện tại nhờ vào khai triển Taylor bậc hai. Cụ thể, xét một hàm số một biến $f(\theta)$ khả vi đến cấp hai. Giả sử ta đang ở bước lặp thứ t với giá trị ước lượng hiện tại là $\theta^{(t)}$. Hàm số $f(\theta)$ xung quanh điểm $\theta^{(t)}$ có thể được xấp xỉ bằng đa thức Taylor bậc hai như sau:

$$f(\theta) \approx f(\theta^{(t)}) + f'(\theta^{(t)})(\theta - \theta^{(t)}) + \frac{1}{2}f''(\theta^{(t)})(\theta - \theta^{(t)})^2. \quad (8.20)$$

Để tìm điểm θ làm cho hàm xấp xỉ bậc hai này đạt cực trị, ta tiến hành lấy đạo hàm của biểu thức xấp xỉ trên theo biến θ và giải phương trình đạo hàm bằng 0:

$$\begin{aligned} \frac{d}{d\theta} \left[f(\theta^{(t)}) + f'(\theta^{(t)})(\theta - \theta^{(t)}) + \frac{1}{2}f''(\theta^{(t)})(\theta - \theta^{(t)})^2 \right] &= 0 \\ \Rightarrow 0 + f'(\theta^{(t)}) + f''(\theta^{(t)})(\theta - \theta^{(t)}) &= 0. \end{aligned} \quad (8.21)$$

Giá trị θ nghiệm của phương trình tuyến tính trên chính là điểm cập nhật tiếp theo, ký hiệu là $\theta^{(t+1)}$. Biến đổi đại số đoạn này ta thu được quy tắc cập nhật Newton-Raphson một biến:

$$\begin{aligned} f''(\theta^{(t)})(\theta^{(t+1)} - \theta^{(t)}) &= -f'(\theta^{(t)}) \\ \Rightarrow \theta^{(t+1)} &= \theta^{(t)} - \frac{f'(\theta^{(t)})}{f''(\theta^{(t)})}. \end{aligned} \quad (8.22)$$

Công thức này cho thấy phương pháp Newton hoạt động tương tự như thuật toán giảm dần đạo hàm, nhưng tốc độ học (learning rate) được tự động điều chỉnh một cách thông minh bằng nghịch đảo của đạo hàm bậc hai $\frac{1}{f''(\theta^{(t)})}$ dựa trên độ cong của không gian hàm mục tiêu. Trong trường hợp nhiều biến, áp dụng cho vector tham số mở rộng $\tilde{\theta}$, nếu $\nabla f(\tilde{\theta})$ là gradient và $H(\tilde{\theta})$ là ma trận Hessian (xem Chương 6), thì khai triển Newton đa biến có dạng:

$$\tilde{\theta}^{(t+1)} = \tilde{\theta}^{(t)} - H(\tilde{\theta}^{(t)})^{-1} \nabla f(\tilde{\theta}^{(t)}). \quad (8.23)$$

Áp dụng cho hồi quy logistic, vì mục tiêu của chúng ta là cực đại hóa hàm log-likelihood ℓ , ta đặt hàm cần cực tiểu hóa là $f(\tilde{\theta}) = -\ell(\tilde{\theta})$ (âm log-likelihood). Từ đó, ta thu được quy tắc cập nhật tham số từng bước để tìm nghiệm tối ưu.

8.6 Hồi quy softmax

8.6.1 Mở rộng hồi quy logistic cho bài toán phân loại đa lớp

Cho đến đây, ta mới xét bài toán mà biến đầu ra chỉ nhận hai giá trị 0 và 1. Tuy nhiên, trong nhiều bài toán thực tế, đầu ra có thể thuộc nhiều hơn hai lớp. Chẳng hạn, trong bài toán nhận dạng chữ số viết tay, một ảnh có thể thuộc một trong mười lớp từ 0 đến 9. Khi đó, ta cần một mô hình tổng quát hơn hồi quy logistic nhị phân. Ý tưởng tự nhiên nhất là mở rộng hồi quy logistic từ hai lớp sang K lớp. Mô hình mở rộng này thường được gọi là hồi quy softmax (softmax regression).

Giả sử biến đầu ra Y nhận một trong K giá trị:

$$Y \in \{1, 2, \dots, K\}. \quad (8.24)$$

Tương tự như hồi quy logistic nhị phân, để biểu diễn công thức gọn gàng, ta áp dụng kỹ thuật mở rộng vector cho mỗi lớp k . Với mỗi lớp k , ta gán một vector tham số mở rộng riêng $\tilde{\theta}^{(k)} = [\theta_0^{(k)}, (\theta^{(k)})^\top]^\top$. Với vector đầu vào mở rộng $\tilde{\mathbf{x}} = [1, \mathbf{x}^\top]^\top$, ta định nghĩa một điểm số tuyến tính cho lớp k :

$$s_k(\tilde{\mathbf{x}}) = \tilde{\theta}^{(k)\top} \tilde{\mathbf{x}}, \quad (8.25)$$

đại lượng $s_k(\tilde{\mathbf{x}})$ này phản ánh mức độ phù hợp của đầu vào $\mathbf{x}$ với lớp k . Vấn đề đặt ra là làm thế nào biến các điểm số này thành các xác suất hợp lệ, tức là các số không âm và có tổng bằng 1. Nếu trong bài toán nhị phân ta dùng hàm logistic để biến một giá trị thực thành một xác suất trong khoảng $(0, 1)$, thì trong bài toán đa lớp ta dùng hàm softmax để biến K điểm số thực thành K xác suất như sau:

$$\Pr(Y = k \mid \tilde{\mathbf{X}} = \tilde{\mathbf{x}}) = \frac{e^{s_k(\tilde{\mathbf{x}})}}{\sum_{j=1}^K e^{s_j(\tilde{\mathbf{x}})}} = \frac{e^{\tilde{\theta}^{(k)\top} \tilde{\mathbf{x}}}}{\sum_{j=1}^K e^{\tilde{\theta}^{(j)\top} \tilde{\mathbf{x}}}}. \quad (8.26)$$

Công thức này đảm bảo hai tính chất rất quan trọng: mọi xác suất đều dương, và tổng các xác suất bằng 1. Để ý rằng, trong hồi quy softmax, nếu ta cộng cùng một hằng số $c(\tilde{\mathbf{x}})$ vào mọi điểm số $s_k(\tilde{\mathbf{x}})$, thì xác suất không thay đổi:

$$\frac{e^{s_k(\tilde{\mathbf{x}}) + c(\tilde{\mathbf{x}})}}{\sum_{j=1}^K e^{s_j(\tilde{\mathbf{x}}) + c(\tilde{\mathbf{x}})}} = \frac{e^{c(\tilde{\mathbf{x}})} e^{s_k(\tilde{\mathbf{x}})}}{e^{c(\tilde{\mathbf{x}})} \sum_{j=1}^K e^{s_j(\tilde{\mathbf{x}})}} = \frac{e^{s_k(\tilde{\mathbf{x}})}}{\sum_{j=1}^K e^{s_j(\tilde{\mathbf{x}})}}. \quad (8.27)$$

Điều này có nghĩa là tham số của hồi quy softmax không được xác định duy nhất. Ta có thể thay đổi tất cả các bộ tham số theo cùng một cách mà vẫn nhận được đúng các xác suất cũ. Đó là lý do trong thực hành và trong lý thuyết, người ta thường chọn một lớp làm lớp mốc (reference class), rồi cố định tham số của lớp đó bằng vector không (ví dụ: $\tilde{\theta}^{(1)} = \mathbf{0}$), và ước lượng tham số cho $K - 1$ lớp còn lại.

8.6.2 Hàm mất mát của hồi quy softmax

Giống như hồi quy logistic, hồi quy softmax được huấn luyện bằng phương pháp ước lượng hợp lý cực đại. Với mỗi mẫu dữ liệu $(\mathbf{x}_i, y_i)$, xác suất mà mô hình gán cho nhãn đúng thông qua biểu diễn mở rộng là:

$$\Pr(Y = y_i \mid \tilde{\mathbf{X}} = \tilde{\mathbf{x}}_i) = \frac{e^{s_{y_i}(\tilde{\mathbf{x}}_i)}}{\sum_{j=1}^K e^{s_j(\tilde{\mathbf{x}}_i)}}. \quad (8.28)$$

Do đó, hàm hợp lý (likelihood) của toàn bộ dữ liệu đối với tập tham số là:

$$L = \prod_{i=1}^n \Pr(Y = y_i \mid \tilde{\mathbf{X}} = \tilde{\mathbf{x}}_i) = \prod_{i=1}^n \frac{e^{s_{y_i}(\tilde{\mathbf{x}}_i)}}{\sum_{j=1}^K e^{s_j(\tilde{\mathbf{x}}_i)}}. \quad (8.29)$$

Lấy log, ta được log-likelihood:

$$\ell = \sum_{i=1}^n \left[s_{y_i}(\tilde{\mathbf{x}}_i) - \log \left(\sum_{j=1}^K e^{s_j(\tilde{\mathbf{x}}_i)} \right) \right]. \quad (8.30)$$

Cực đại hóa log-likelihood tương đương với cực tiểu hóa âm log-likelihood:

$$-\ell = \sum_{i=1}^n \left[-s_{y_i}(\tilde{\mathbf{x}}_i) + \log \left(\sum_{j=1}^K e^{s_j(\tilde{\mathbf{x}}_i)} \right) \right]. \quad (8.31)$$

Đây chính là hàm mất mát cross-entropy đa lớp thường gặp trong học máy. Vì vậy, từ góc nhìn hiện đại, hồi quy softmax có thể được xem là một mô hình tuyến tính đầu ra softmax, được học bằng hàm mất mát cross-entropy.

8.7 Học tổ hợp

Ở phần trên, chúng ta đã được làm quen với mô hình rừng ngẫu nhiên, và tiếp cận với một ý tưởng quan trọng trong học máy, đó là kết hợp nhiều mô hình yếu để được một mô hình mạnh hơn. Đây là một kỹ thuật quan trọng giúp làm tăng độ chính xác của mô hình, nhất là khi chúng ta làm việc với các bộ dữ liệu có số lượng không đủ lớn. Kỹ thuật này được gọi là học tổ hợp (ensemble learning).

Về trực quan, học tổ hợp có thể được hiểu như việc sử dụng một hội đồng chuyên gia. Mỗi chuyên gia đưa ra một nhận định riêng. Nếu các chuyên gia đủ tốt và không mắc đúng cùng một sai lầm, thì việc tổng hợp ý kiến của họ thường cho kết quả đáng tin cậy hơn so với chỉ nghe một người. Xuất phát từ trực quan này, phương pháp học tổ hợp sẽ sử dụng nhiều mô hình, mỗi mô hình đưa ra kết quả dựa trên một góc nhìn khác nhau; và việc tổ hợp kết quả dự đoán từ nhiều mô hình con sẽ giúp cho dự đoán cuối cùng ổn định và chính xác hơn. Đối với các tác vụ hồi quy, cách tổ hợp đơn giản nhất là lấy trung bình các dự đoán. Đối với các tác vụ phân loại, ta có thể